Departamento de Informática

Lab02

Leonor Rebola

Adriana Abreu

Faculdade de Engenharia
Departmento de Informática
Licenciatura em Inteligência Artificial e Ciência de Dados

Covilhã, Março 2026

Página intencionalmente deixada em branco.

Departamento de Informática

Lab02

Leonor Rebola

Nº Estudante 53663

Adriana Abreu

Nº Estudante 53672

Professor: Sebastião Pais
Professor de Extração e Transformação de Dados,
Universidade da Beira Interior

Faculdade de Engenharia
Departmento de Informática
Licenciatura em Inteligência Artificial e Ciência de Dados

Covilhã, Março 2026

Página intencionalmente deixada em branco.

Conteúdo

Conteúdo 4

Lista de Figuras 5

1 Introdução 6

2 Contexto, explicação e descrição 7

3 Registos e estatísticas 10

4 Conclusão 15

Lista de Figuras

2.1 Demonstração das colunas 9

3.1 Top 10 artigos com mais conteúdo 11
3.2 Top 5 paginas com mais links 12
3.3 Top 10 paginas com mais imagens 13
3.4 Estatísticas do tamanho do conteúdo 14

1

Introdução

No âmbito da Unidade Curricular de Extração e Transformação de Dados, foi proposto o desenvolvimento de um sistema de Web Crawling e Web Scraping.
O objetivo deste trabalho é extrair e transformar dados não estruturados provenientes da web, permitindo a recolha automatizada de informações relevantes, como títulos, resumos e hiperligações, a partir da Wikipédia. Para tal, foram aplicadas técnicas de navegação automatizada e extração de elementos HTML, culminando no armazenamento estruturado dos dados, garantindo o respeito pelas políticas de acesso e robots.txt da plataforma.

2

Contexto, explicação e descrição

Para a realização deste lab escolhemos trabalhar com a Wikipédia por ser um website de fácil acesso a informação e com uma grande quantidade de dados.

Começamos por realizar um código em Python para a Extração dos dados onde decidimos extrair o url, o título, o texto, os links, e imagens.

```
import requests
from bs4 import BeautifulSoup
import csv
import time
import logging

# configuração do logging
logging.basicConfig(
    filename="crawler.log",
    level=logging.ERROR,
    format="%(asctime)s - %(levelname)s - %(message)s"
)

headers = {"User-Agent": "Mozilla/5.0"}

start_url = "https://en.wikipedia.org/wiki/Web_scraping"

visited = set()
queue = [start_url]

with open("wikipedia_dataset.csv", "w", newline="", encoding="utf-8")
    as f:

    writer = csv.writer(f)
    writer.writerow(["url", "title", "text", "links", "images"])

    while queue and len(visited) < 752:

        url = queue.pop(0)

```

```
        if url in visited:
            continue

        print("Visiting:", url)

        visited.add(url)

        try:
            response = requests.get(url, headers=headers, timeout=10)
            response.raise_for_status()

            soup = BeautifulSoup(response.text, "html.parser")

        except requests.exceptions.RequestException as e:
            logging.error(f"Erro HTTP em {url}: {e}")
            print("Erro ao aceder:", url)
            continue

        try:
            # título
            title_tag = soup.find("h1")
            title = title_tag.text.strip() if title_tag else "N/A"

            # texto
            paragraphs = soup.find_all("p")
            text = " ".join(p.text for p in paragraphs) if paragraphs
                else ""

            # links
            links = []
            for a in soup.find_all("a"):
                href = a.get("href")

                if href and href.startswith("/wiki/") and ":" not in
                    href:
                    full = "https://en.wikipedia.org" + href
                    links.append(full)

                    if full not in visited:
                        queue.append(full)

            # imagens
            images = []
            for img in soup.find_all("img"):
                src = img.get("src")

                if src:
```

```
                    if src.startswith("//"):
                        src = "https:" + src

                    images.append(src)

            # guardar no CSV
            writer.writerow([
                url,
                title,
                text[:5000],
                ";".join(set(links)),
                ";".join(set(images))
            ])
        #erro ao processar o HTML, como falta de tags ou estrutura
            inesperada
        except Exception as e:
            logging.error(f"Erro ao processar HTML em {url}: {e}")
            print("Erro ao extrair dados:", url)

        time.sleep(1)
```

Fizemos a realização de um documento log para a deteção de erros (não foram detetados nenhuns) e adicionamos exceções para evitar possíveis quebras ao correr o código.

- **Url:** Representa o url da página web.
- **Title:** Representa o título principal da página web.
- **Text:** Representa o texto principal da página web até 5000 caracteres.
- **Links:** Representa todas as ligações de outros urls wikipédia que explicam palavras do própria página web
- **Images:** Representa os links das imagens que estão nas páginas web.

url	title	text	links	images

Figura 2.1: Demonstração das colunas

3

Registos e estatísticas

Para estatísticas e registos, usámos as seguintes queries no SQL e o output gerado são as tabelas que mostramos a seguir:

1. Top 10 artigos com mais conteúdo

```sql
SELECT TOP 10
    title,
    LEN(CAST(text AS VARCHAR(MAX))) AS tamanho_texto
FROM wikipedia
ORDER BY tamanho_texto DESC;
```

2. Top 5 páginas com mais links

```sql
SELECT TOP 5
    title,
    LEN(CAST(links AS VARCHAR(MAX)))
    - LEN(REPLACE(CAST(links AS VARCHAR(MAX)), ';', '')) + 1 AS
        numero_links
FROM wikipedia
ORDER BY numero_links DESC;
```

3. Top 10 páginas com mais imagens

```sql
SELECT TOP 10
    title,
    LEN(CAST(images AS VARCHAR(MAX)))
    - LEN(REPLACE(CAST(images AS VARCHAR(MAX)), ';', '')) + 1 AS
        numero_imagens
FROM wikipedia
ORDER BY numero_imagens DESC;
```

4. Estatísticas do tamanho do conteúdo

```sql
SELECT
    AVG(LEN(CAST(text AS VARCHAR(MAX)))) AS media_tamanho_texto,
    MIN(LEN(CAST(text AS VARCHAR(MAX)))) AS menor_texto,
    MAX(LEN(CAST(text AS VARCHAR(MAX)))) AS maior_texto
FROM wikipedia;
```

	title	tamanho_texto
1	Topological data analysis	5010
2	Naive Bayes classifier	5002
3	Data augmentation	4995
4	Data synchronization	4962
5	Robustness computer science	4949
6	Data masking	4929
7	Data loss	4922
8	Data editing	4919
9	Auction sniping	4913
10	Link farm	4913

Figura 3.1: Top 10 artigos com mais conteúdo

Esta tabela detalha as páginas com maior volume de texto, liderada pelos artigos Topological data analysis (5010 caracteres) e Naive Bayes classifier (5002 caracteres). É interessante notar que o topo desta lista é dominado por conceitos técnicos e científicos de ciência de dados e informática, o que reflete a densidade e o rigor documental típicos deste tipo de temas na plataforma.

	title	numero_links
1	March 9	775
2	March 8	769
3	March 10	759
4	List of Internet toplevel domains	740
5	1891	737

Figura 3.2: Top 5 paginas com mais links

A análise aos links internos revelou um padrão muito peculiar da arquitetura da Wikipédia. As páginas com mais ligações são referentes a datas de calendário (ex: March 9, March 8). Este fenómeno justifica-se pelo facto de estas páginas funcionarem como agregadores massivos, listando centenas de eventos históricos, nascimentos e óbitos, e gerando consequentemente centenas de links (mais de 750 por artigo).

	title	numero_imagens
1	NASA	201
2	Topological data analysis	142
3	Royal Air Force	127
4	Lockheed C130 Hercules	120
5	Google	108
6	Naive Bayes classifier	105
7	1957	99
8	Hawaii	98
9	Commonwealth of Nations	95
10	1956	94

Figura 3.3: Top 10 paginas com mais imagens

A contagem de imagens por página revelou resultados bastante coerentes com os temas tratados. O artigo sobre a NASA destaca-se isoladamente na primeira posição com 201 imagens, algo expectável dada a vasta documentação fotográfica de missões e espaço. Seguem-se artigos de forte cariz histórico ou institucional (como a Royal Air Force ou a Google), que tradicionalmente requerem forte apoio visual.

	media_tamanho_texto	menor_texto	maior_texto
1	4018	52	5010

Figura 3.4: Estatísticas do tamanho do conteúdo

Através das funções de agregação, foi possível analisar a distribuição do conteúdo textual. Observa-se que a média de tamanho dos textos recolhidos ronda os 4018 caracteres. Os dados revelam ainda uma grande disparidade natural na Wikipédia, capturando desde pequenos artigos ou "esboços"(com apenas 52 caracteres) até publicações extensas e detalhadas (com 5010 caracteres).

4

Conclusão

Após a realização do Lab02 chegamos à conclusão que não houve grandes dificuldades no trabalho.